

**Proyecto 1: Analítica de contratación pública**

**Integrantes:**

Juan José Mora Wilches - 202211162

Juan Pablo Cortés Monroy-202121492

Daniel Felipe Nova Pulido - 202212669

**Entidad elegida:**

SENA

**Usuario final elegido:**

Responsable de planeación y seguimiento de la contratación de prestación de servicios del  
SENA

## Soporte 2: Extracción y limpieza de datos

**Rol:** Ingeniería de datos

**Responsables:** Daniel Felipe Nova Pulido, Juan Pablo Cortés Monroy y Juan José Mora Wilches.

### 1. Fuente y carga inicial


Se trabajó con el archivo de Contratos Electrónicos de SECOP II suministrado para el proyecto. El archivo original tenía aproximadamente 10,5 GB, 89 columnas y 5.979.791 registros.

URL del archivo original: <https://tinyurl.com/actd2620-proy1>

El archivo fue cargado en un bucket de Amazon S3 para posteriormente catalogarlo y consultarlo mediante AWS Glue y Amazon Athena.

Buckets creados:

- bucket-entrada-sena
  - o datos-raw
    - datos originales en csv de 10.5gb
- Bucket-salida-sena



### 2. Primer intento de catalogación con AWS Glue

Inicialmente se creó un clasificador CSV y un Glue Crawler para identificar el esquema del archivo y crear una tabla consultable desde Athena.

El clasificador utilizaba:

- delimitador ,;

## Analítica Computacional para la Toma de Decisiones

- comillas dobles ";
- encabezados definidos para las 89 columnas;
- OpenCSVSerde.

Sin embargo, al consultar la tabla creada se detectaron inconsistencias. Algunas columnas aparecían desplazadas o con valores nulos y Athena contabilizaba aproximadamente 27 millones de filas, a pesar de que la fuente original contenía cerca de 6 millones.

The screenshot displays the AWS Athena console interface. The top section, titled 'sena-csv-clasificador', shows the 'Classifier properties' for a classifier named 'sena-csv-clasificador'. The properties include: Name (sena-csv-clasificador), Contains header (Has headings), Allow single column (False), Header (a long list of column names), CSV Serde (OpenCSVSerde), Creation time (September 13, 2026 at 02:40:30), Delimiter (,), Last updated (September 13, 2026 at 02:40:30), Disable value trimming (False), Version (1), Quote symbol ("), and Custom datatypes (None).

The bottom section shows a query in the Amazon SageMaker Unified Studio. The query is: `SELECT COUNT(*) AS total_filas FROM datos_raw;`. The query status is 'Completed'. The results show a single row with the value 27136922 for the column 'total\_filas'.

### 3. Diagnóstico del problema

Se validó localmente el archivo original utilizando Python y Pandas:

`df.shape`

Resultado:

(5.979.791, 89)

También se verificaron campos críticos como:

nombre\_entidad

nit\_entidad

id\_contrato

documento\_proveedor

valor\_del\_contrato

valor\_pagado

Los valores estaban correctamente alineados en la fuente.

El problema provenía de que algunos campos de texto del CSV contenían saltos de línea dentro de valores encerrados entre comillas. Aunque esos saltos hacían parte de una misma fila lógica, el mecanismo de lectura inicial terminaba interpretándolos como nuevos registros.

Por esta razón Athena generaba muchas más filas de las existentes realmente.

#### **4. Corrección mediante AWS Glue**

Para corregir el problema se utilizó un AWS Glue Job con Spark, leyendo directamente el archivo almacenado en S3.

La lectura del CSV se configuró con soporte para campos multilinea:

```
.option("header", "true")
```

```
.option("multiLine", "true")
```

```
.option("quote", "")
```

```
.option("escape", "")
```

```
.option("encoding", "UTF-8")
```

```
.option("mode", "FAILFAST")
```

También se renombraron las primeras cuatro columnas de metadatos de Socrata:

```
:id      → meta_id
```

```
:version → meta_version
```

```
:created_at → meta_created_at
```

```
:updated_at → meta_updated_at
```

Se verificó que el dataframe generado tuviera las 89 columnas esperadas.

## Analítica Computacional para la Toma de Decisiones

Posteriormente, los datos fueron escritos en formato Parquet con compresión Snappy en S3.

s3://.../datos-parquet/

La conversión redujo considerablemente el tamaño del conjunto y permitió una lectura estructurada y eficiente.

The image displays three screenshots from the AWS management console, illustrating the workflow for data processing and storage.

**Top Screenshot: AWS Glue Studio**

The interface shows the 'Get Started' section with four options: 'Visual ETL' (Author in a visual interface focused on data flow), 'Notebook' (Author using an interactive code notebook), 'Script editor' (Author code with a script editor), and 'Set up' (Use SageMaker Unified Studio Notebooks, an immersive, serverless workspace). Below this, the 'Your jobs (1)' section shows a table with one job:

| Job name           | Type     | Created by | Last modified             | AWS Glue version | Action                          |
|--------------------|----------|------------|---------------------------|------------------|---------------------------------|
| sena-csv-a-parquet | Glue ETL | Script     | 12/9/2026, 10:46:35 p. m. | 5.1              | <a href="#">Upgrade with AI</a> |

**Middle Screenshot: Monitoring**

The 'Monitoring' section shows a 'Job runs summary' with the following metrics:

- Total runs: 1
- Running: 0
- Canceled: 0
- Successful runs: 1
- Failed runs: 0
- Run success rate: 100%
- DPU hours: 1

Below the summary, the 'Job runs (1)' section shows a table with one job run:

| Job name           | Run status | Type     | Start time (Local)  | End time (Local)    | Run time  | Capacity | Worker type | DPU hours |
|--------------------|------------|----------|---------------------|---------------------|-----------|----------|-------------|-----------|
| sena-csv-a-parquet | Succeeded  | Glue ETL | 09/12/2026 22:46:56 | 09/12/2026 22:53:38 | 7 minutes | 4        | G.2X        | 0.44      |

**Bottom Screenshot: Amazon S3 console**


The 'bucket-entrada-sena' bucket is shown with two folders: 'datos-parquet/' and 'datos-raw/'. The 'datos-parquet/' folder is selected, showing its properties and a list of objects. The objects list shows one object:

| Name                                                               | Type    | Last modified                            | Size   | Storage class |
|--------------------------------------------------------------------|---------|------------------------------------------|--------|---------------|
| part-00000-d6a2149-9a4d-411b-b00e-a731db728c23-c000.snappy.parquet | parquet | September 12, 2026, 22:47:42 (UTC-05:00) | 2.6 GB | Standard      |

## 5. Nuevo catálogo y validación en Athena

Se ejecutó un nuevo Glue Crawler, esta vez sobre los archivos Parquet generados, produciendo la tabla datos\_parquet en el Bucket de entrada.

## Analítica Computacional para la Toma de Decisiones



| Name                                 | State | Schedule | Last run                 | Last run timestamp             | Log                      | Table changes from last run |
|--------------------------------------|-------|----------|--------------------------|--------------------------------|--------------------------|-----------------------------|
| <a href="#">crawler-sena</a>         | Ready |          | <span>✓</span> Succeeded | September 13, 2026 at 03:02:22 | <a href="#">View log</a> | 1 created                   |
| <a href="#">sena-parquet-crawler</a> | Ready |          | <span>✓</span> Succeeded | September 13, 2026 at 03:56:51 | <a href="#">View log</a> | 1 created                   |

Luego se verificó el número total de registros desde Athena:


```
SELECT COUNT(*) AS total_filas
```

```
FROM datos_parquet;
```

Resultado:

5.979.791

Este valor coincidió exactamente con el conteo realizado sobre la fuente original en Python.



Query in Amazon SageMaker Unified Studio

Use your IAM role to analyze and build with your existing AWS resources in a single data and AI development environment.

Editor | Recent queries | Saved queries | Query settings

Workgroup: Projector1-JED

Data source: AwsDataCatalog | Catalog: None | Database: sena-parquet-db

Tables and views: [Create](#)

SQL: `SELECT COUNT(*) AS total_filas FROM datos_parquet;`

Query results: [Copy](#) [Download results CSV](#)

Results (1)

| # | total_filas |
|---|-------------|
| 1 | 5979791     |

Esta validación confirmó que el problema de lectura había sido corregido.

### 6. Extracción de contratos del SENA

Se identificaron las entidades correspondientes al SENA mediante una expresión regular que contemplaba tanto la sigla como el nombre completo:

```
SELECT COUNT(*) AS total_sena
```

```
FROM datos_parquet
```

```
WHERE regexp_like(
```

```
    lower(nombre_entidad),
```

```
    '([^[^a-z])sena([^[^a-z])$)|servicio nacional de aprendizaje'
```


```
);
```

Resultado:

328.057

Este resultado coincidió con la extracción realizada localmente con Pandas.

También se verificaron los distintos valores de nombre\_entidad, obteniendo 88 variantes asociadas al SENA.



La extracción final fue:

SELECT \*

FROM datos\_parquet

WHERE regexp\_like(

lower(nombre\_entidad),

'^(^[a-z])sena([a-z]|\$)|servicio nacional de aprendizaje'

);


El resultado fue descargado como:

datos\_filtrados\_raw.csv

con:

328.057 filas × 89 columnas

## Analítica Computacional para la Toma de Decisiones



### 7. Limpieza y alistamiento en Python

El archivo extraído se procesó posteriormente en el notebook:

limpieza.ipynb

Se seleccionaron 26 variables relevantes para las preguntas de negocio y se realizaron las principales tareas de limpieza.

#### Tipos de datos:

Se convirtieron las variables de fecha:

fecha\_de\_firma

fecha\_de\_inicio\_del\_contrato

fecha\_de\_fin\_del\_contrato

fecha\_de\_notificaci\_n\_de\_prorrogaci\_n

a formato datetime.

Los identificadores como:

nit\_entidad

codigo\_entidad

documento\_proveedor

se trataron como texto y no como cantidades numéricas.

#### Valores faltantes:

Se revisaron los datos faltantes y se decidió no imputar fechas contractuales artificialmente, utilizando únicamente registros válidos cuando una variable específica fuera necesaria.

**Duplicados:**

No se encontraron filas completamente duplicadas:

**Variables derivadas:**

Se construyeron variables utilizadas posteriormente en los análisis:

anio\_firma

mes\_firma

duracion\_dias

duracion\_inconsistente

unspsc

regional

es\_prorrogable

tiene\_notificacion\_prorroga

es\_contratacion\_individual

## **8. Validación de duración contractual**

La duración contractual se calculó mediante:

fecha\_fin - fecha\_inicio

Se encontraron únicamente 9 contratos con duración negativa.

En lugar de eliminar estos registros o modificar sus fechas originales:

- se creó `duracion_inconsistente = True`;
- `duracion_dias` se marcó como faltante para esos casos.

Esto permitió conservar la trazabilidad del registro original.

## **9. Preparación del código UNSPSC**

Los códigos originales aparecían en formatos como:

V1.80111600

Por lo que se extrajo el código de ocho dígitos:

80111600

Se conservaron como faltantes los casos en los que no fue posible identificar un código, sin asignar categorías artificiales.

## **10. Variable regional**

Para facilitar el análisis territorial se creó la variable:

regional

principalmente a partir del departamento.

Los registros asociados a:

DIRECCION GENERAL

SECRETARIA GENERAL

se clasificaron como:

Nivel Central

Esta categoría corresponde a una construcción analítica utilizada para diferenciar la administración central de las dependencias territoriales.

## **11. Identificación de contratación individual**

Para las preguntas relacionadas con personas naturales se construyó:

es\_contratacion\_individual

considerando contratos que cumplieran simultáneamente:

tipo\_de\_contrato = Prestación de servicios

+

tipo de documento correspondiente a persona natural

+

es\_grupo = No

Se identificaron 281.635 registros que cumplen esta definición.

La variable se conservó dentro del dataset general para permitir que cada análisis aplicara posteriormente el filtro requerido.

## **12. Resultado de la limpieza**

El resultado final fue exportado como:

`datos_limpios.csv`

con 328.057 registros correspondientes a los contratos del SENA, incluyendo las variables originales seleccionadas y las variables derivadas durante el proceso de alistamiento.

Este archivo fue utilizado posteriormente como fuente común para los tres análisis de datos y para la preparación del tablero.