

Proyecto 1: Analítica de contratación pública

Integrantes:

Juan José Mora Wilches - 202211162

Juan Pablo Cortés Monroy - 202121492

Daniel Felipe Nova Pulido - 202212669

Entidad elegida:

SENA

Usuario final elegido:

Responsable de planeación y seguimiento de la contratación de prestación de servicios del
SENA

Analítica Computacional para la Toma de Decisiones

Pregunta 1: ¿Cuál es el tamaño y la concentración del gasto del SENA en contratos de prestación de servicios con personas naturales, y en qué categorías de servicio (UNSPSC) y regionales se concentra?

Rol: Análisis de negocio y análisis de datos

Responsable: Daniel Felipe Nova Pulido

Objetivo del análisis: El objetivo es dimensionar este tipo de contratación e identificar los servicios y regiones que concentran una mayor proporción del valor contratado, como apoyo a la planeación y seguimiento contractual.

Análisis de datos:

De los 328.057 registros del SENA, se identificaron 281.635 (85,85%) como contratos de prestación de servicios con personas naturales. Durante la exploración se detectaron 137 registros monetarios extremos que representaban el 99,99% del valor bruto inicial, por lo que se separaron del análisis monetario para evitar que distorsionaran los resultados. Las principales cifras del análisis:

Indicador	Resultado
Valor contratado analizado	\$9,56 billones
Contratos	281.498
Personas	80.946
Valor promedio por contrato	\$33,96 millones
Valor mediano por contrato	\$36,09 millones

Las contrataciones analizadas corresponden al periodo disponible entre octubre de 2017 y agosto de 2026.

Hallazgos:

- El valor contratado presenta una alta concentración por tipo de servicio. La categoría 80111600 - Servicios de personal temporal representa el 54,04% del total; las cinco principales categorías UNSPSC concentran el 82,45%.
- La concentración territorial es menor. Bogotá representa el 14,86% del valor contratado y Antioquia el 11,64%; las cinco principales regionales reúnen el 44,66%.
- Por tanto, la contratación está mucho más concentrada por tipo de servicio que por ubicación geográfica.
- Se encontraron diferencias estadísticamente significativas en la distribución del valor contractual entre las cinco principales regionales mediante la prueba de Kruskal-Wallis ($p < 0,001$).

Nota: las cifras corresponden a valor contratado, no necesariamente a valor efectivamente pagado.

Nivel Central agrupa Dirección General y Secretaría General.

Analítica Computacional para la Toma de Decisiones

Pregunta 2: ¿Qué tan recurrente es la contratación de las mismas personas (mismo Documento Proveedor) a lo largo del tiempo, y qué tan comunes son las prórrogas?

Rol: Análisis de negocio y análisis de datos

Responsable: Juan José Mora Wilches

Objetivo del análisis: Identificar si existe una relación entre la recurrencia en la contratación de un mismo proveedor y la probabilidad de que sus contratos sean prorrogados, como apoyo al seguimiento y planeación de la contratación de prestación de servicios.

Análisis de datos:

A partir de los 328.057 contratos analizados, se agrupó la información por proveedores según el número de contratos que han tenido con el SENA. Posteriormente, se calculó la proporción de contratos prorrogados dentro de cada grupo de recurrencia, considerando como prórroga aquellos contratos con $\text{dias_adicionados} > 0$.

Los principales resultados del análisis fueron:

Grupo de recurrencia	Contratos	Contratos prorrogados	Tasa de prórroga
1 contrato	28.057	1.736	6,19%
2–3 contratos	63.972	4.791	7,49%
4–5 contratos	57.256	4.679	8,17%
6–10 contratos	146.654	14.014	9,56%
Más de 10 contratos	32.118	3.250	10,12%

Hallazgos:

- Se observa una relación creciente entre la recurrencia del proveedor y la frecuencia de las prórrogas. La tasa pasa de 6,19% para proveedores con un solo contrato a 10,12% para aquellos con más de 10 contratos.
- Los proveedores con más de 10 contratos presentan una tasa de prórroga 3,93 puntos porcentuales superior a la de los proveedores con un único contrato.
- La tasa de prórroga aumenta progresivamente a medida que aumenta la recurrencia: 6,19% $\rightarrow$ 7,49% $\rightarrow$ 8,17% $\rightarrow$ 9,56% $\rightarrow$ 10,12%.
- Los resultados sugieren que los proveedores más recurrentes tienen una mayor frecuencia de prórrogas, lo que puede ser relevante para la planeación y seguimiento de contratos recurrentes.
- Esta relación debe interpretarse como una asociación observada en los datos, y no necesariamente como una relación causal entre la recurrencia y la decisión de prorrogar.

Nota: Se considera que un contrato tuvo prórroga cuando $\text{dias_adicionados} > 0$. La tasa de prórroga se calculó sobre el total de contratos pertenecientes a cada grupo de recurrencia.

Pregunta 3: ¿En qué departamentos/regionales y en qué meses del año se concentra la firma de estos contratos (estacionalidad)?

Rol: Análisis de negocio y análisis de datos

Responsable: Juan Pablo Cortés Monroy

Objetivo del análisis: Identificar en qué regionales y en qué meses del año se concentra la firma de contratos de prestación de servicios con personas naturales, para apoyar la planeación de la carga administrativa de contratación y anticipar los periodos/regionales de mayor demanda de gestión.

Análisis de datos:

Se analizaron 281,635 contratos de prestación de servicios con personas naturales algo equivalente al 85.8% del total de contratación del SENA en el periodo, sobre 328,057 registros de la base de datos limpia, distribuidos en 34 regionales. Se construyeron las siguientes variables mes_firma y regional para el análisis de concentración, y se aplicaron una prueba estadística de chi-cuadrado para comprobar la independencia entre mes y regional.

Regional	# de contratos	% del total
Bogotá D.C	43.259	15.4%
Antioquia	31.393	11.1%
Valle del Cauca	19.404	6.9%
Atlántico	17.296	6.1%
Santander	15.827	5.6%
Cundinamarca	11.792	4.2%
Periodo	# de contratos	% del total
Enero	118.327	42.0%
Febrero	85.034	30.2%
Los otros meses	78.274	27.8%

Hallazgos:

La contratación está fuertemente concentrada tanto en el espacio como en el tiempo: solo 6 de las 34 regionales agrupan el 49.3% de los contratos (con Bogotá y Antioquia solas sumando 26.5%), y el 72.2% de toda la contratación anual se firma en enero y febrero. El chi-cuadrado de independencia ($\chi^2=8791.2$, $gl=99$, $p<0.001$) confirma que este patrón mensual no es uniforme entre regionales cada una concentra su carga en momentos distintos del año, por lo que un calendario único de planeación nacional no captura bien la realidad operativa de todas.

Para mejorar la contratación en enero–febrero concentrado en Bogotá, Antioquia, Valle y Atlántico, se recomienda reforzar temporalmente su gestión y escalonar los procesos a lo largo del año.

Ingeniería de Datos:

Rol: Ingeniería de datos

Responsables: Daniel Felipe Nova Pulido, Juan Pablo Cortés Monroy y Juan José Mora Wilches

Extracción y procesamiento:

Se trabajó con la base de Contratos Electrónicos de SECOP II que dio el profesor, con aproximadamente 6 millones de registros. El archivo original, de cerca de 10,5 GB, fue almacenado en Amazon S3 y posteriormente procesado mediante AWS Glue y Athena.

Durante la primera carga se detectó un problema de interpretación del CSV: algunos campos contenían saltos de línea dentro de texto entre comillas, que el parser utilizado inicialmente interpretaba como nuevas filas. Como consecuencia, Athena llegó a mostrar más de 27 millones de registros, aunque el archivo original contenía alrededor de 6 millones.

Para corregirlo se utilizó un job de AWS Glue con Spark, configurando la lectura del CSV con soporte para registros multilínea. El resultado se almacenó en formato Parquet con compresión Snappy, reduciendo considerablemente el tamaño y permitiendo una lectura correcta y más eficiente.

Validación y extracción del SENA:

Sobre los archivos Parquet se ejecutó un nuevo Glue Crawler para construir el catálogo de datos y consultar la información desde Athena. Se validó que la tabla resultante tuviera exactamente 5.979.791 registros, lo que correspondía con los datos originales cargados.

Posteriormente se filtraron las entidades correspondientes al SENA, obteniendo 328.057 contratos. Este resultado coincidió con la validación realizada localmente en Python con los datos raw.

Limpieza y alistamiento:

El subconjunto del SENA se descargó en formato CSV y se procesó en Python con Pandas (archivo limpieza.ipynb). Se realizaron, entre otras, las siguientes tareas:

- selección de variables relevantes;
- conversión de fechas y tipos de datos;
- revisión de valores faltantes y duplicados;
- creación de variables como año, mes, duración contractual, regional y código UNSPSC;
- identificación de contratación de prestación de servicios con personas naturales;
- validación de inconsistencias sin eliminar información de forma injustificada.

El resultado final fue datos_limpios.csv, utilizado posteriormente por los tres análisis de negocio y como base para el tablero.

Diseño y Desarrollo del Tablero de Datos:

Rol: Tablero de datos

Responsables: Juan Pablo Cortés Monroy y Juan José Mora Wilches

Aporte Pregunta 1 - Daniel Felipe Nova: se definieron como indicadores el valor contratado, contratos, personas y valor mediano; como dimensiones de filtro año, regional y UNSPSC; y como visualizaciones principales la concentración por categoría y regional. Para los cálculos monetarios se excluyen los 137 registros extremos identificados. Hecho en el archivo analisis_pregunta1.ipynb.

Para el desarrollo del tablero de información, se recopiló información de la fuente principal cambiando por el enfoque de cada una de las preguntas planteadas, para el diseño del tablero se consideraron algunos de los resultados obtenidos en base al análisis de datos previamente realizado

Evaluación:

Teniendo en cuenta los resultados anteriormente encontrados, podemos afirmar que los análisis muestran que la contratación de prestación de servicios con personas naturales constituye una parte fundamental de la contratación del SENA, representando el 85,85% de los registros y un valor contratado analizado de aproximadamente \$9,56 billones. Esta contratación presenta una alta concentración por tipo de servicio, ya que las cinco principales categorías UNSPSC reúnen el 82,45% del valor contratado, mientras que territorialmente las cinco principales regionales concentran el 44,66%, adicionalmente existe una marcada concentración temporal, pues el 72,2% de los contratos se firma en enero y febrero, con una concentración particularmente importante en regionales como Bogotá, Antioquia, Valle del Cauca y Atlántico. Por último, se muestra una relación creciente entre la recurrencia de los proveedores y la frecuencia de las prórrogas. Esto sugiere que los proveedores más recurrentes pueden ser un grupo relevante para el seguimiento y la planeación anticipada de los contratos.

A partir de estos hallazgos, se proponen una serie de acciones orientadas a fortalecer la planeación y el seguimiento de la contratación. Principalmente, se recomienda anticipar y distribuir la gestión de los procesos de contratación, especialmente durante los meses de enero y febrero, mediante una planeación previa que permita reducir el tiempo en las regionales con mayor volumen. Asimismo, se propone implementar un sistema de priorización por regional y categoría UNSPSC, que permita asignar recursos de acuerdo con la concentración de contratos y valor contratado. La recurrencia de los proveedores podría incorporarse como un indicador de atención ya que aquellos con mayor número de contratos y mayor frecuencia histórica de prórrogas puedan ser identificados con anticipación para realizar seguimiento. Finalmente, se recomienda tener en cuenta las siguientes medidas de control: alertas tempranas que integre información sobre volumen, valor, regional, categoría, recurrencia y vencimiento de contratos, permitiendo al responsable de planeación pasar de un seguimiento principalmente descriptivo a una gestión focalizada y basada en datos.

Despliegue y Mantenimiento:

Rol: Despliegue y mantenimiento

Responsable: Daniel Felipe Nova Pulido

El tablero interactivo se desplegó en una instancia Amazon EC2 con Amazon Linux, permitiendo el acceso remoto a las tres preguntas de negocio mediante una dirección pública estable. Se configuró una Elastic IP para evitar cambios en la URL durante el periodo de evaluación y se habilitó el puerto TCP 8050 en el Security Group para permitir el acceso externo a la aplicación Dash.

Proceso de despliegue. Se preparó la instancia instalando Python y las dependencias requeridas (dash, pandas, plotly y scipy). Posteriormente se transfirieron el archivo de la aplicación, el conjunto de datos limpio y los estilos CSS mediante SSH/SCP. La aplicación se configuró para escuchar en 0.0.0.0:8050.

Durante la primera ejecución con una instancia t3.micro, el sistema finalizó el proceso por falta de memoria al cargar el conjunto de datos y las librerías. Como solución, la instancia se escaló a t3a.small (2 GB de RAM).

Disponibilidad y mantenimiento.

El tablero se dejó ejecutándose en segundo plano mediante:

```
nohup python3 Tablero_Dash.py > tablero.log 2>&1 &
```

Esto permite mantener la aplicación disponible aunque se cierre la sesión SSH.

Resultado. El tablero quedó disponible públicamente en:

<http://44.196.65.163:8050>

